



Yapay Sinir Ağları, Derin Öğrenme Modelleri ve Uygulama Alanları

Murathan SEVİNÇ

Bilgisayar Mühendisliği
Nisan 2024

1 Giriş

Derin öğrenme makine öğreniminin bir koludur. Makine öğreniminin başlarından günümüze kadar geçen süreçte yapay zekaya olan ilgi giderek artmış ve günümüzde en çok kullanılan yapay zeka algoritmaları olan derin öğrenme mimarilerinin ortaya çıkmasını sağlamıştır. Derin öğrenme mimarileri ile birlikte yapay zeka problemlerinin çözümü için pek çok derin öğrenme yaklaşımları geliştirilmiştir. Endüstri, tıp, robotik, görüntü işleme, bilgisayar görmesi, nesne tespiti, ses işleme-tanıma, çeviri, gelecek tahmini, finansal gibi pek çok alanda akıllı çözümler üretmektedir. Bu çalışmada, derin öğrenme mimarileri ve algoritmaları incelenerek, literatürde yapılmış çalışmalar ışığında uygulama alanları temelinde başarımları değerlendirilmiştir. Derin öğrenme mimarileri ile birlikte derin öğrenmede kullanılan kütüphanelere yer verilmiştir. Bununla beraber farklı problemlerin çözümlerine yönelik geliştirilen derin öğrenme mimarileri yer almaktadır.

Anahtar kelimeler: Derin öğrenme, Yapay sinir ağları, Derin CNN, Konvolüsyonel sinir ağları

Günümüz mühendislik uygulamalarında insan gibi düşünen, insan gibi davranışlar sergileyen uygulamalara ağırlık verilmektedir. İnsan olgusunun mühendislik uygulamalarında yer alması için kullanılan adlandırma makine öğrenmesi olarak bilinir (Goldberg ve Holland, 1988; Quinlan, 1986). İnsanın hayatı boyunca öğrendiği şeylerin günlük yaşamda hayatını kolaylaştırdığı ve deneyimlerine göre hareket ettiğini örnek alarak aynı şekilde makine öğrenmesi gerçekleştirilmeye çalışılmaktadır. Makine öğrenmesinin özellikle sanayide üretim kademesinde işlerin hızlandırılması, ürün kalitesinin artırılması, ürünlerin sınıflandırılması vb. gibi işlemleri hızlıca yapması için kullanımı tercih edilmektedir (Sebastiani, 2002; Jordan ve Mitchell, 2015). Bunun dışında güvenlik uygulamalarında, sınıflandırma, medikal teşhis ve tanı uygulamalarında, ileriye dönük tahminsel yaklaşımlarda vb. (Michalski vd, 20013; Sommer ve

Paxson, 2010; Buczak ve Guven, 2016; Kourou vd, 2015; Holder vd., 2017) gibi pek çok alanda kullanımı artmakta ve hayatı kolaylaştırmaktadır. Bu gibi uygulamaların gerçekleştirilmesi için kullanılan makine öğrenmesindeki temel nokta insan beynindeki nöronların çalışmasından faydalanılarak benzer bir yaklaşımla makinanın öğrenmesini ve buna göre davranmasını sağlamaktır (Fukushima, 1975). İnsan beynindeki sinir hücrelerinin çalışma mantığından faydalanılarak yapay sinir hücre modeli oluşturulmuştur (Harvey, 1994). Bu yapay sinir hücre modeli zaman içerisinde geliştirilmiş ve makine öğrenmesinde sıklıkla kullanılmaya başlanmıştır. Günümüzde bu yapay sinir hücre mantığı daha ileri seviyelere taşınarak derin öğrenme mantıklı bir model kullanılmaya başlanmıştır (Hinton vd., 2006). Yapay sinir ağı insan beyninin öğrenme sürecinden etkilenerek ortaya atılmış bir yaklaşımdır.

Bu yaklaşım ilk kez 1943 yılında insan beyindeki hücrelerin yapısının matematiksel modellenmesi oluşturularak gerçekleştirilmiştir (McCulloch ve Pitts, 1943). Burada temel amaç insan beyninin öğrenmesini sağlayan sinir hücrelerinin matematiksel olarak modellenerek bir bilgisayar sisteminin benzer bir yaklaşım sergilemesini sağlamaktır. Bir insanın öğrenmesi yan yana gelen sinapsların birbiriyle olan bağlantılarıyla gerçekleşir (Hebb, 1949). Sayısallaştırılmış bir sinir hücresi mantığı ile yapay sinir ağları oluşturulmuştur. Yapay sinir ağındaki matematiksel yaklaşımla basit bir sinir ağı modellenmesi yapılmış ve bilgisayar sistemlerinde uygulanması amaçlanmıştır. Sonraki yıllarda Hebb bu sinir hücrelerinin tekrar eden durumlar karşılığında öğrenmenin arttığını belirlemiştir. Bu işlemde nöronların matematiksel modellenmesi nöronların gücünün artırılması gerektiğini ortaya koymuştur (Hebb 1949).




Figure 1: Bir Sinir Hücresinin Matematiksel Modeli [1]
(Perceptron Sinir Hücresi Modeli)

Figure 1’de bir sinir hücresinin matematiksel modeli gösterilmiştir. Burada X1, X2, X3 ile belirtilen her bir dentriti göstermektedir. Dentritlere ait ağırlıklar ise W1, W2, W3 ile gösterilmektedir (Sarle, 1994). Her bir sinyalin toplandığı Net ise çekirdeği temsil etmektedir. Tüm sinyallerin ağırlıkları ile çarpılarak toplam elde edilmektedir. Elde edilen Net toplam değeri bir sonraki nörona belirli bir eşik değeri ile gönderilmesi için F(Net) transfer fonksiyonu ile gerçekleştirilmekte. F(Net) için kullanılacak 3 temel fonksiyon vardır.

Keskin limitli transfer fonksiyonunun da giriş değeri 0’dan küçük içe çıkış değeri 0’dır. Giriş değeri 0’dan büyük ise çıkış değeri +1 değerini alır. Eşik değeri fonksiyonunda ise girdi değeri toplamda 0 ve daha küçük ise 0, 1 ve daha büyük girişler için 1, 0 ile 1 arasındaki değerlerde ise kendini alır. Sigmoid fonksiyonu süreklilik gösteren ve türevi alınabilen bir fonksiyondur. Doğrusal olmaması sebebiyle sıklıkla tercih edilmektedir. Girdi değerine bağlı olarak 0-1 aralığında bir değer alır (Stein, 1956)

1956 yılında Dartmouth'ta düzenlenen bir konferansta zeka ile donatılmış bir bilgisayar programını gerçekleştirme olanağını araştırmayı öne sürmüşlerdir. Böylelikle yapay zeka terimi kullanılmıştır. (J. McCarthy vd., 1956), LISP ile yapılan satranç oyunu oynayan mantık teorisi üzerine kurulu ilk yapay zeka programı üretilmiştir. 1958 yılında Frank Rosenblatt örüntü sınıflandırma için iki katmanlı perceptron ağını önermiştir (Rosenblatt, 1958). Daha sonra Robinson geliştirdiği yapay zeka algoritmasında çözünürlük ilkesine dayanan makine odaklı bir mantık makalesini yayınlamıştır (Robinson, 1965). 1970'li yılların ortalarına kadar yapay sinir ağlarının karanlık döneme girip durma noktasına gelmiştir. Bu dönemde XOR probleminin çözülemediği olması yapay zekanın geleceği konusunda ciddi kaygılara yol açmıştır. Ve yapay zeka bu noktadan sonra duraklama dönemine girmiştir (Minsky, 1969). 1970 ve 1980'li yıllar arasında bilgiye dayalı sistemler ağırlıkla yer almıştır. 1970'lerin ortalarında XOR probleminin çözümü üzerine yaklaşım getirmiştir (Werbos, 1974). Hopfield neuro biyolojik yapıların makinalar içinde uygulanabilirliği konusunda yayınladığı bir makale ile makine öğrenimine dikkat çekmiştir (Hopfield, 1982). 1986 yılında yayınlanan bir kitapta paralel dağıtık sistemlere ait problemlerin çözümleri ortaya konmuştur. Burada XOR probleminin çözümü de yer almaktadır (McClelland, 1986). Aynı yıl Fukushima yaptığı çalışma ile örüntü tanıma için bir yaklaşım getirmiştir (Fukushima, 1986). Daha sonra Broomhead ve Lowe yaptıkları

çalışma ile radial tabanlı sistemleri çok katmanlı sistemlere alternatif olarak geliştirmişlerdir (Broomhead ve Lowe, 1988). Probabilistik ağlar (Specht 1988) ve genel regasyon ağları (Specht, 1991) ortaya konmuştur. Yapılan çalışmalarla yapay zeka, yeniden yön bulmuştur. Pek çok bilimsel çalışmalarda kullanılır hale gelmiştir (Yadav, 2015).

Yapay sinir ağı modeli teorisiyle birlikte makine öğrenmesi konusunda bir çağ başlatılmıştır. İnsan düşüncelerine göre karar verme yetisi yapay sinir ağı modeli ile makinelere de geçmiştir. Lineer denklemlerin çözümünde başarılı sonuçlar elde edilmiştir (Sajikumar ve Thandaveswara, 1999). Literatüre bu yöntemle kazandırılmış pek çok yaklaşım yer almaktadır. Yapılan çalışmalarda ileri beslemeli yapay sinir ağı modeli kullanılmış ve başarı oranı belirli bir sınırdan kalmıştır (Morris ve Rubin, 1991).

İlk yapılan yapay sinir ağı modelinde tek katmanlı ileri beslemeli yapay sinir ağı modeli kullanılmıştır (Lippmann, 1987). Elde edilen sonuçlar belirli bir oranda kalmış ve üzerine çıkamamıştır. Daha sonrasında yapılan çalışmalarda geri beslemeli sinir ağı modeli oluşturulmuştur. Geri beslemeli sinir ağı modeli ile elde edilen sonuçlar üzerinde düzenlemeler yapılarak daha başarılı sonuçlara ulaşılmıştır. Yapay sinir ağı modelleri ile yapılan çalışmalar artarken halen lineer denklemlerde sağlıklı çalışan bu sistem lineer olmayan sistemlerde çalışmamakta ve doğru sonuçlar üretilmemektedir (Jain vd., 1996).

Linear olmayan problemlerin çözüme ulaşması çok katmanlı yapay sinir ağı modeli ortaya çıkarmış ve geri beslemeli çok katmanlı sinir ağı modeli ile lineer olmayan denklemler çözüme kavuşmuş. Ve sinir ağlarına olan ilgi yeniden artmıştı (Eberhart ve Kennedy, 1995). Çok katmanlı sinir ağı modelinin ortaya çıkmasıyla birlikte katman sayısının artırılarak daha iyi sonuçlar vermesi için Convolutional Neural Network (CNN) geliştirilmiştir. Burada yer alan sinir ağı modelinde gizli katmanlar yer almakta ve elde edilen sonuçlar oldukça başarılı olmaktadır (Pan vd., 2000). Konvolüsyonel sinir ağlarının gelişmesi ile birlikte sınıflandırma işlemleri daha başarılı sonuçlar vermiştir. Konvolüsyon işlemi ile obje üzerindeki hatlar belirli hale getiriliyor ve sinir ağı modeli içine dahil ediliyordu (LeCun ve Bengio, 1995). 2006 yılında Geoffrey Hinton ve Ruslan Salakhutdinov tarafından yayınlanan makale ile derin öğrenme terimi ortaya atılmış ve derin öğrenme çalışmaları başlamıştır (Hinton ve Salakhutdinov, 2006). Sinir ağlarının gelişim süreci tablo 1’de verilmektedir.

Tablo1. Sinir ağlarının tarihsel dönüm noktaları

| Yıllar | Gerçekleşen | Yayıncı |
|--------|-------------------------------------------------------------------------------------|-----------------------------------------|
| 1940 | Elektronik Beyin (1943) | S. McCulloch, W. Pitts |
| 1950 | Perceptron – Tek katmanlı algılayıcı (1957) | M. Hoff, B. Widrow, F. Rosenblatt |
| 1960 | Multi Layer Perceptron- Çok katmanlı algılayıcı (1965) | A.G. Ivakhnenko, V.G. Lapa |
| 1970 | Neocognitron (1979) | K. Fukushima |
| 1980 | Backpropagation (1986) | D.Rumelhart, G.Hinton, R.Williams |
| 1990 | XOR probleminin ortaya çıkışı Destek Vektör Makineleri (SVM-Support Vector Machine) | S. Hochreiter Schölkopf, Burges, Vapnik |
| 2000 | - | - |
| 2010 | Deep Neural Networks – Derin Sinir ağları (2006) | G. Hinton |

2 Derin Öğrenme Materyal ve Yöntemleri

Hinton’un yapmış olduğu çalışmalarla yayınlamış olduğu makalede yapay sinir ağlarına yeni bir yaklaşım getirmiştir. Bu yaklaşım derin öğrenme (Deep Convolution Neural Network) olarak adlandırılmıştır (Hinton vd., 2006). Konvolüsyonel sinir ağları çok katmanlı sinir ağları olarak bilinmektedir. Bu sinir ağı sistemiyle önemli çalışmalar yapılmış ve başarıları yüksek sonuçlar elde edilmiştir. Derin konvolüsyonel sinir ağı elde edilen bu başarımları daha yüksek seviyelere çıkararak önemli bir başarıya imza atmıştır (Krizhevsky vd., 2012; LeCun vd., 1998; Szegedy vd., 2015; Zeiler ve Fergus, 2013; Szegedy vd., 2015).

Konvolüsyonel sinir ağı ile sinyal işleme, video analizi, görüntü analizi ve tespiti, sınıflandırma, medikal görüntü işleme gibi pek çok alanda önemli işler çıkarmıştır. Bu sinir ağı kullanılırken bazı aşamalar gerçekleştirilmektedir. Bunlar ön işlem, özellik çıkarımı ve sınıflandırma-tespit şeklinde tanımlanmaktadır. Her bir aşamasında özel yaklaşımlar sergilenmekte ve doğruluğu artırmaya yönelik çalışmalar yapılmaktadır. Özellikle özellik çıkarım işlemi için pek çok farklı yaklaşım sunulmuştur. Özellikle çıkarım ile tespit edilmesi istenen olaya ait belirgin noktalar ortaya çıkarılmaya çalışılmaktadır. Sonraki süreçte ise yapay sinir ağları kullanılarak belirlenen özelliklere ait sınıfın tespiti için sinir ağları kullanılmaktadır (Snoek vd., 2005; Li vd., 2010; Scherer vd., 2010).

Derin öğrenme ile daha önce yapılan pek çok işlem bir arada yürütülerek sonuca gidilmektedir. Burada özellikle ön işlem ve özellik çıkarımı gibi yapılar göz ardı edilmekte ve sinir ağı içerisinde bu işlemler otomatik olarak yapılmaktadır. Derin konvolüsyonel sinir ağında özellik çıkarımı ağı içerisinde belirlenmekte ve katmanlar içerisinde tespit edilmesi istenen yapıya ait özellikler belirlenmektedir. Alt katman ile üst katman arasında bağlantılı hiyerarşik bir yapı bulunmaktadır. Özellik çıkarımı için özel bir safha bulunmamaktadır. Katmanlar içerisindeki yapıda nesne-olaya ait belirgin özellikler belirlenmekte (Hinton ve Salakhutdinov, 2006) ve sonraki katmana aktarılmaktadır (Bengio, 2009). Şekil 2' de yer alan görüntüde uydu görüntülerini sınıflandırılmasını sağlayan konvolüsyonel sinir ağı modeli yer almaktadır (Doğan ve Türkoğlu, 2017).

Yapay sinir ağlarında sınıflandırma yapılırken kullanılan 3 temel öğrenme yapısı vardır bunlar öğretmenli öğrenme (Supervised) (Shipp vd., 2002), öğretmensiz öğrenme (Un-supervised) (Hastie, 2009) ve takviyeli öğrenmedir (Reinforcement) (Chapelle, 2006).

Öğretmenli öğrenmede yapay sinir ağına giriş verisi olan $y(t)$ verisi, çıkışta $d(t)$ olarak çıkacağı bilgisi verilmiştir. Oluşturulan sinir ağı içerisinde sonuca ulaşmak için ağırlıklar belirlenir. Bu ağırlıklara göre $y(t)$ girdi verisinin $d(t)$ çıkış sonucunu elde edilmesi için verilen örneklerle göre ağırlıklar güncellenir. Ağırlıkların güncellenmesi işlemi belirlenen iterasyon sayısı kadar devam ederek öğrenme işlemi gerçekleşir (Shipp vd., 2002).

Öğretmensiz öğrenmede ise bir çıkış bilgisi verilmeksizin giriş görüntüleri ağına girişine uygulanır. Ağıdaki katmanlarda sonuç verisi oluşturulur. Buna göre oluşan çıkışlarda benzer değerlere sahip olan sonuçlar bir kümeye alınır. Oluşan her bir küme bir sınıfı temsil eder (Hastie, 2009).

Takviyeli öğrenmede ise ağına giren verinin çıkış verisi ne olması gerektiği konusunda bir bilgi verilmez. Girdi verisinin çıkışı üretilmesi beklenir. Bir öğretmen yardımıyla üretilen çıkışa göre sonucun doğru ya da yanlış olduğu bilgisi verilir. Girdi verisi yanlış sonucu ürettiğinde ağı ağırlıklarının doğru sonucu üretmesi için tekrar güncelleme yapar (Chapelle, 2006).

2.1 Konvolüsyonel Sinir Ağları (Convolutional Neural Network)

Çok katmanlı ileri beslemeli bir yapay sinir ağı olan konvolüsyonel sinir ağı (CNN) özellikle görüntü analizlerinin yapılması için kullanılmaktadır. Hayvan görü sistemine dayanan bir yaklaşımla ortaya atılmıştır (Hubel ve Wiesel, 1968). Filtrelemeye dayalı bir yapıdadır. Kullanılacak olan filtre ile görüntünün özelliğini belirtecek öznitelikler belirgin hale getirir. Özellikle sınıflandırıcı işlemlerinde başarılı sonuçlar üretmektedir. Filtreler farklı boyut ve değerlerde kullanılarak baskınlık düzeyi az olan özniteliklerin ortaya çıkmasını sağlar (Fukushima, 1982; Simard, 2003). Şekil 2'de konvolüsyonel sinir ağına ait örnek bir mimari görülmektedir.


İlk olarak LeCun ve arkadaşları tarafından gradyan temelli bir yaklaşım sunulurken ortaya çıkan ağı yapısına konvolüsyonel sinir ağı adı verilmiştir. Oluşturulan bu yapay sinir ağına ise LeNet adı verilmiştir (LeCun vd., 1998). Çok katmanlı bu sinir ağı içerisinde birden fazla konvolüsyon katmanı, tam bağlı katman, aktivasyon katmanı, sınıflandırıcı katman, havuzlama katmanı ve bunlara ek katmanlar yer almaktadır. Her katman kendi işlevini yürüterek sınıflandırıcı katmanda sonuç üretilmektedir. Derin öğrenme yapıları içerisinde en çok kullanılan sinir ağı konvolüsyonel sinir ağlarıdır. Daha çok sınıflandırma ve tespit işlemleri için kullanılmaktadır. Sinir ağı içerisindeki katmanlarla sınıflandırılacak öğelere ait öznitelikler belirlenerek sınıflandırıcı katmanı ile öğeler sınıflandırılır.

2.2 Tekrarlayan Sinir Ağı (Recurrent Neural Network)

Elman tarafından tasarlanan basit tekrarlayan sinir ağları (Simple Recurrent Network-SRN) dil bilimciler ve psikanaliz için çığır açan bir yaklaşım olmuştur. Elmanın yayınladığı makalede konuşma akışı üzerindeki gizli yapı üzerinde çalışılan bir öğrenme sürecini temsil ediyordu. Örüntü kümelemesinde fiil ve isim kategorizasyonu açık şekilde birbirinden ayrılıyordu. Ayrıca canlı-cansız, insan-hayvan, avcı-yırtıcı gibi kategorilerde ayrılmıştı. (Elman, 1990).

Tekrarlayan sinir ağları(RNN), sadece ağı giren giriş örneklerini değil daha önce zaman serisi içerisindeki giriş örneklerini de alır. Bu sinir ağının amacı ardıl şekilde gelen verilerin kullanılmasıdır. Geleneksel sinir ağlarında girişler birbirlerinden bağımsız olarak ağı giriş yapar.

Ya da kurulacak bir cümlede art arda gelen kelimelerin akabinde cümlemin devamının nasıl geleceğini gösteren kelimenin tahmin edilmesi işlemi örnek olarak verilebilir. İki tür RNN vardır bunlar; İki yönlü RNN'ler (Bidirectional RNNs) (Schuster ve Paliwal, 1997) ve Derin RNN'lerdir (Deep RNNs) (Schmidhuber, 1992).




Tekrarlayan sinir ağı modeli [2]

2.3 Uzun-KısaSüreli Hafıza (LSTM- Long Short-Term Memory)

RNN mimarilerinde zaman dizeleri aralarında bağlam boşlukları olması halinde sonraki dizenin tahmin edilmesi çok zor bir durumdur (Bengio vd., 1994). Bu durum RNN'ler için oldukça dezavantajlı bir durumdur. Hochreiter ve Schmidhuber yapmış oldukları çalışmada bu durumu ortadan kaldıracak uzun ve kısa süreli hafıza LSTM öne sürmüşlerdir (Hochreiter ve Schmidhuber, 1997).

LSTM ağlarının RNN ağlarından bir farkı yoktur. Fakat gizli durumu hesaplamak için LSTM ağlarında bir yapı kullanılır. LSTM içerisinde hafıza hücreleri yer alır. Önceki durumu ve girdi bilgisini tutan bir hücredir. Ağ mimarisi içerisinde yer alan bu hücreler hangi verinin tutulacağına ya da hangi verinin sileneceğine karar verirler. Sonraki aşamada ise önceki durumu mevcut bellek ile giriş verisini birleştirirler. Böyle bir yaklaşımla uzun vadeli bağımlılıkların ortadan kaldırılarak veri dizilerinin devam ettirilmesi mümkün kılınır.




Şekilde LSTM bloğu yer almaktadır. Burada yer alan gözetleme ve unutma kapısında unutma kapısı durumu sıfırlamak, gözetleme kapısı bağlantıları öğrenmeyi kolaylaştırmak için kullanılmaktadır (Gers vd., 1999; Gers ve Schmidhuber, 2000).

2.4 Kısıtlı Boltzmann Makinesi (RBMRestricted Boltzmann Machine)

1987 yılında Hinton, Sejnowski ve Ackley tarafından yayınlanan makale ile öğrenme algoritmalarının prensipleri anlatılmıştır. Simetri prensibiyle hücreler arası bağlantılarla yenilemeli kısıtları yapmanın Boltzmann Makinesi ile olabileceğini ortaya atmışlardır (Ackley vd., 1987).

1993 yılında Kappen yayınladığı “Olasılık Tahmininde Boltzmann Makinelerini Kullanmak: Sinir Ağı Öğrenimi için Genel Bir Yapı” başlıklı makalesinde, Boltzmann Perceptron modeli ile bir uygulama yapmıştır. Bu uygulamada bileşik olasılıksal dağılımları tahmin edebileceğini belirtmiştir (Kappen, 1994).


Her bir düğüm bir nörondur. Ve hesaplamalar bu düğümlerde yapılır. Her düğüm gizli katmanda yer alan bir başka düğümler (nöron) ile bağlanır. Aynı katmandaki düğümler birbirleriyle bağlanmazlar. Yani katmanlar arası iletişim yoktur. Bu yüzden kısıtlı boltzman makineleri olarak adlandırılır. Görünür katmanda girdiler hesaplanır ve bir sonraki düğüme o girdiyi iletilip ileilmeyeceği rastgele olarak belirlenir (Hinton, 2012).



Kısıtlı Boltzman Makinesi [3]


2.5 Derin İnanç Ağı (DBN-Deep Belief Network)

Hinton RBM'i kullanarak Derin İnanç Ağları (DBN) yığını oluşturmuş ve bu ağı eğitilip eğitilebileceğini göstermiştir. Derin inanç ağları veri setinin hiyerarşik temsilini çıkarmayı amaçlayan grafiksel modellerdir. Örnek bir makine yapısı, şekil 8'de gösterilmiştir. Şekilde görünür giriş katmanını h_1 ise gizli katmanı temsil eder. Art arda eklenen kısıtlı boltzman makineleri katmanlarından oluşan bir sinir ağı yaklaşımıdır. Kısıtlı boltzman makinelerinin sırasıyla eğitilerek öğrenilmesiyle gerçekleşir. Giriş uygulanan veri ile gizli katman arasında olasılıksal bir dağılım modellenir (Hinton, 2006).



Ard arda gelen kısıtlı boltzman makineleri örneği [4]

Grafiksel model katmanından oluşan hem yönlendirilmiş hem de yönsüz kenarlı bir sinir ağı sınıfıdır (Boureau, 2008). Örüntü tanıma ve üretme konularında etkindir (Huang vd., 2007; Bengio vd., 2007). Denetimsiz ön tanımlı bir sinir ağıdır. Derin inanç ağı modeli örneği şekil 9'da görülmektedir.




Derin inanç ağı modeli [5]

2.6 Derin Oto-kodlayıcılar (Auto Encoder)

Yapay sinir ağı modellerinden biri olan derin oto kodlayıcılar denetimsiz öğrenme tabanlı makine öğrenme sistemidir. Bu sinir ağı diablo ağı olarakta adlandırılmaktadır (Bengio, 2009; Lu, 2013). Yıllarca sinir ağlarının temel bir parçası olmuştur (Hinton ve Zemel, 1994). Derin öğrenme mimarilerinin ortaya çıkmasıyla beraber derin öğrenme mimarileri içerisinde yer almaya başlamıştır (Baldi, 2012). Oto kodlayıcılar giriş veri kümesini sıkıştırarak en az kayıpla en iyi öğrenmeyi amaçlar. İleri beslemeli bir sinir ağıdır (Krizhevsky ve Hinton, 2011).

Temel olarak 3 katmandan oluşmaktadır. Girdi katmanı, gizli katman ve çıktı katmanı. Giriş ve çıkış katmanındaki nöron sayıları eşit olmakla birlikte gizli katmandaki nöron sayısı değişkenlik göstermektedir. Şekil 10'de bu durum gösteren oto kodlayıcı görülmektedir. Gizli katman içerisindeki nöronların sayısı giriş ve çıkış katmanında yer alan nöronlardan daha az olduğunda veri kümesi sıkıştırılır. Böylelikle daha az veri ağ içerisinde yer alır. Bu da ağı performansında etkili olmaktadır (Vincent vd., 2010; Vincent vd., 2008).



Oto Kodlayıcı şeması [6]

3 Derin Öğrenme Katmanları

- Giriş (Input) Katmanı
- Konvolüsyon (Convolution) katmanı
- Aktivasyon (Relu) katmanı
- Havuzlama (Pooling) Katmanı
- Tam Bağlı (Full-Connected) Katman
- Dropout Katmanı
- Sınıflandırma (Classification) katmanı
- Yumuşatma (Softmax) Katmanı
- Normalizasyon (Normalization) Katmanı

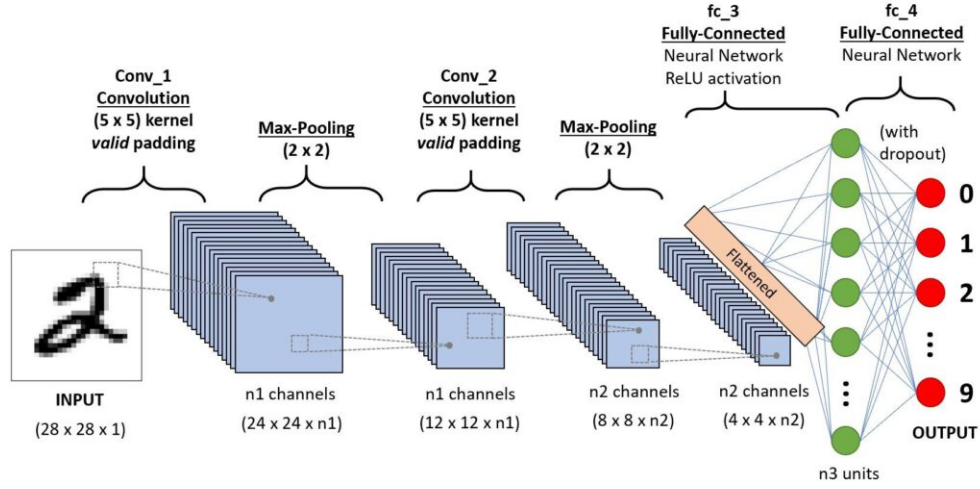


Figure 2: Derin Öğrenme Katmanları [7]

4 Derin Öğrenme Algoritmaları

- LeNet
- AlexNet
- ZF Net
- VggNet
- GoogleNet
- ResNet

Tablo 2.Derin öğrenme algoritmaları

| Yıl | Derin Öğrenme Algoritması | Geliştirici | Hata Oranı | Parametre Sayısı |
|------|---------------------------|---------------------------------|------------|------------------|
| 1998 | LeNet | Yann LeCun ve Arkadaşları | | 60Bin |
| 2012 | AlexNet | Alex Krizhevsky,Geoffrey Hinton | %15.3 | 60Milyon |
| 2013 | ZFNet | Matthew Zeiler ve Rob Fergus | %14.8 | |
| 2014 | GoogleNet | Google | %6.67 | 4Milyon |
| 2014 | VGGNet | Simonyan, Zisserman | %7.3 | 138Milyon |
| 2015 | ResNet | Kaiming He | %3.6 | |

5 Derin Öğrenme Kütüphaneleri

- Tensorflow
- Caffe
- Theano
- Torch
- DeepLearning4j
- Keras
- Lasagne
- Cognitive Network Toolkit (CNTK)
- DIGIT
- Pylearn2
- MXNET

6 Derin Öğrenmenin Uygulama Alanları

- Bilgisayar Görmesi (Computer Vision)
- Sınıflandırma (Classification)
- Nesne Tespiti (Object Detection)
- Ses (Audi-Wave-Speech)
- Medikal (Medical)
- Endüstri (Industrial)

7 Sonuçlar ve Tartışma

Yapay zeka mimarileri geçmişten günümüze gelindiğinde pek çok alanlarda kullanılmaktadır. Yapay zeka yaklaşımlarının tarihsel gelişimi makine öğrenmesinin ne denli bir hızla geliştiğini göstermektedir. Elektronik ve bilgisayar sistemlerinin hemen hepsinde kontrol, denetim, tahmin, modifikasyon, üretim, eğlence amaçlı bir yaklaşımı görmek mümkün. Caddede bilboardlarda, oyun salonlarında, araba, uçakta, dinlediğimiz bir müzikte, izlediğimiz bir filmde, televizyonlarda pek çok uygulamada, hava tahminlerinde, hastanede, güvenlik sistemlerinde, savunma sanayisinde, finansal sektörlerde ve pek çok günlük yaşam aktivasyonlarında görmek mümkündür.

Derin öğrenme sistemlerinin bu kadar geliştiği bir ortamda şirketler, devletler, kurumlar arge için bu konuya ciddi şekilde eğilim göstermişlerdir. Pek çok büyük bilişim şirketi bu konuda atılımlar yapmış yeni yaklaşımlar getirmiştir. Konunun gelişimine göre yeni uygulamalar ve bakış açıları geliştirmişlerdir. Google, Microsoft, Baidu, IBM, Apple, Nvidia,

Facebook, Twitter, Amazon ve daha birçok şirket derin öğrenmeyle ilgili çalışmalar yapmıştır.

Yapılan çalışmalara bakıldığında derin öğrenme mimarileri yapay zeka teknolojilerine yeni bir yaklaşım getirdiği ve çığır açtığı görülmektedir. Derin öğrenme mimarilerinin gelecek tahminlerine yönelik çalışmaları günümüz teknolojilerini birkaç yıl ileri taşıdığı düşünülmektedir. İnsan hayatını kolaylaştırmak, sağlıklı bir yaşam sürdürebilmek için derin öğrenme mimarilerinin çok etkin şekilde hayatımızda yer almaya başladığı görülmektedir.

Gelecekte günlük yaşamın her noktasında yer alacak olan bu mimarilerin otomot bir dünyanın kapısını aralayacağı düşünülmektedir. Kendi kendine gideceği yere varan araçlar, daha güvenli yollar, insansız hava ve kara araçları, taşıma alanında bir başkalaşıma doğru götürecek çalışmalar yapılmaktadır.

Tıp alanında; hastalık tanı ve teşhisin daha hızlı gerçekleştirileceği, doktorun yapmış olduğu ameliyatların bir kısmını robotların yapabileceği, kendi kendine hastaya cevap verebilecek sistemlerin oluşturulabileceği, hastanın sağlık merkezlerine uğramadan tanı-teşhis konabileceği sistemler üzerine çalışmalar yapılmaktadır. Robotik sistemlerde farklı bir noktaya getirecek ve robotların insan yaşamında etkin bir rol oynayacağı bir dünya için pek çok çalışma yapılmaktadır. Pek çok özel şirket insan gücünün yerini robotik sistemlere bırakacağı öncü çalışmalar yap-

maktadır. Tarımsal alanlarda sulama, bakım, gübreleme, toprak analizlerinin otomatik yapılacağı ulusal sistemler için derin öğrenme tabanlı çalışmalar devam etmektedir. Savunma sanayinde kullanılan pek çok yapay zeka teknolojisi bulunmaktadır. Günümüzde pek çok savunma araçları derin öğrenme mimarisi ile donatılmaktadır. Özellikle insansız hava ve kara araçlarında aktif rol almaktadır.

Bu makale ile derin öğrenme mimarileri hakkında bir derleme çalışması sunulmuştur.

References

- [1] <https://images.app.goo.gl/is2vxwDHDjfGFdFi9>
- [2] <https://images.app.goo.gl/hRMT3owAfWgSFNGf9>
- [3] <https://images.app.goo.gl/6F1MvYNmeZjEZahi7>
- [4] <https://images.app.goo.gl/rRhB6x4fNg6LapzX7>
- [5] <https://images.app.goo.gl/tUnQBnVA1uS1vKXB6>
- [6] <https://images.app.goo.gl/ZB6r6mAVUvmHmcHQ7>
- [7] <https://d9v7j6n3.rocketcdn.me/wp-content/uploads/2020/08/convolutional-neural-network-1024x548.jpeg>